バイオインフォマティクス
基本ツール
(ホモロジー検索)

基礎生物学研究所
超階層生物学センター
データ統合解析室

内山郁夫
(uchiyama@nibb.ac.jp)

配列比較とアライメント

```
  GCATGAGGA
GTATGGATAAGA
```

Alignment ↓

```
GCATG---AGGA
GTATGGATAAGA
```

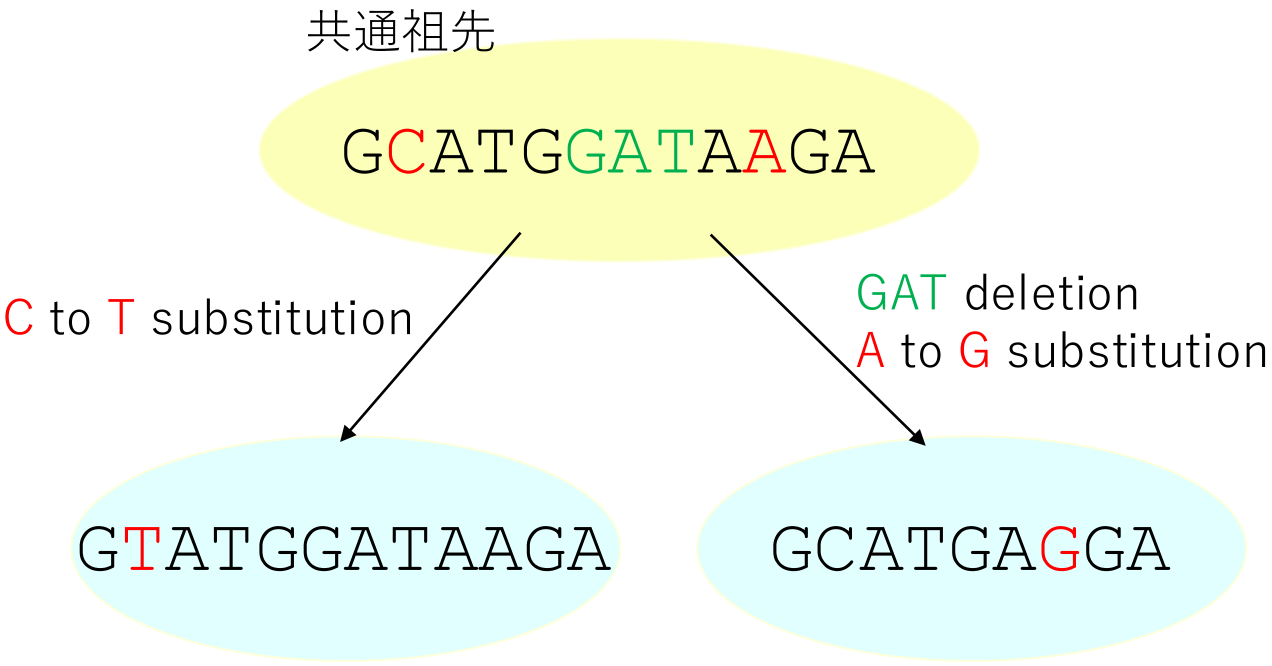

相同性 (homology)：共通祖先の同一の構造から派生した構造であること
相同性は類似性(similarity)に基づいて推定する

類似性スコアと配列アラインメント

GCATGAGGA
GTATGGATAAGA

↓

スコアの定義： 一致 +2、不一致 -1、ギャップ開始 -2、ギャップ延長 -1

GCATG---AGGA
GTATGGATAAGA

+2-1+2+2+2-2-1-1+2-1+2+2 = +8

配列アラインメント：類似性スコアが最大になるように各配列にギャップを挿入して並べる

アミノ酸の類似性行列：BLOSUM62

Higher score is assigned between similar amino acids

	P	A	G	N	Q	D	E	T	S	C	V	I	M	L	K	R	H	F	Y	W
P	7																			
A	-1	4																		
G	-2	0	6																	
N	-2	-2	0	6																
Q	-1	-1	-2	0	5															
D	-1	-2	-1	1	0	6														
E	-1	-1	-2	0	2	2	5													
T	-1	0	-2	0	-1	-1	-1	5												
S	-1	1	0	1	0	0	0	1	4											
C	-3	0	-3	-3	-3	-3	-4	-1	-1	9										
V	-2	0	-3	-3	-2	-3	-2	0	-2	-1	4									
I	-3	-1	-4	-3	-3	-3	-3	-1	-2	-1	3	4								
M	-2	-1	-3	-2	0	-3	-2	-1	-1	-1	1	1	5							
L	-3	-1	-4	-3	-2	-4	-3	-1	-2	-1	1	2	2	4						
K	-1	-1	-2	0	1	-1	1	-1	0	-3	-2	-3	-1	-2	5					
R	-2	-1	-2	0	1	-2	0	-1	-1	-3	-3	-3	-1	-2	2	5				
H	-2	-2	-2	1	0	-1	0	-2	-1	-3	-3	-3	-2	-3	-1	0	8			
F	-4	-2	-3	-3	-3	-3	-3	-2	-2	-2	-1	0	0	0	-3	-3	-1	6		
Y	-3	-2	-3	-2	-1	-3	-2	-2	-2	-2	-1	-1	-1	-1	-2	-2	2	3	7	
W	-4	-3	-2	-4	-2	-4	-3	-2	-3	-2	-3	-3	-1	-2	-3	-3	-2	1	2	11

small

amide

acidic

hydroxyl

aliphatic (V,I,L)

basic

aromatic

類似性（相同性）検索

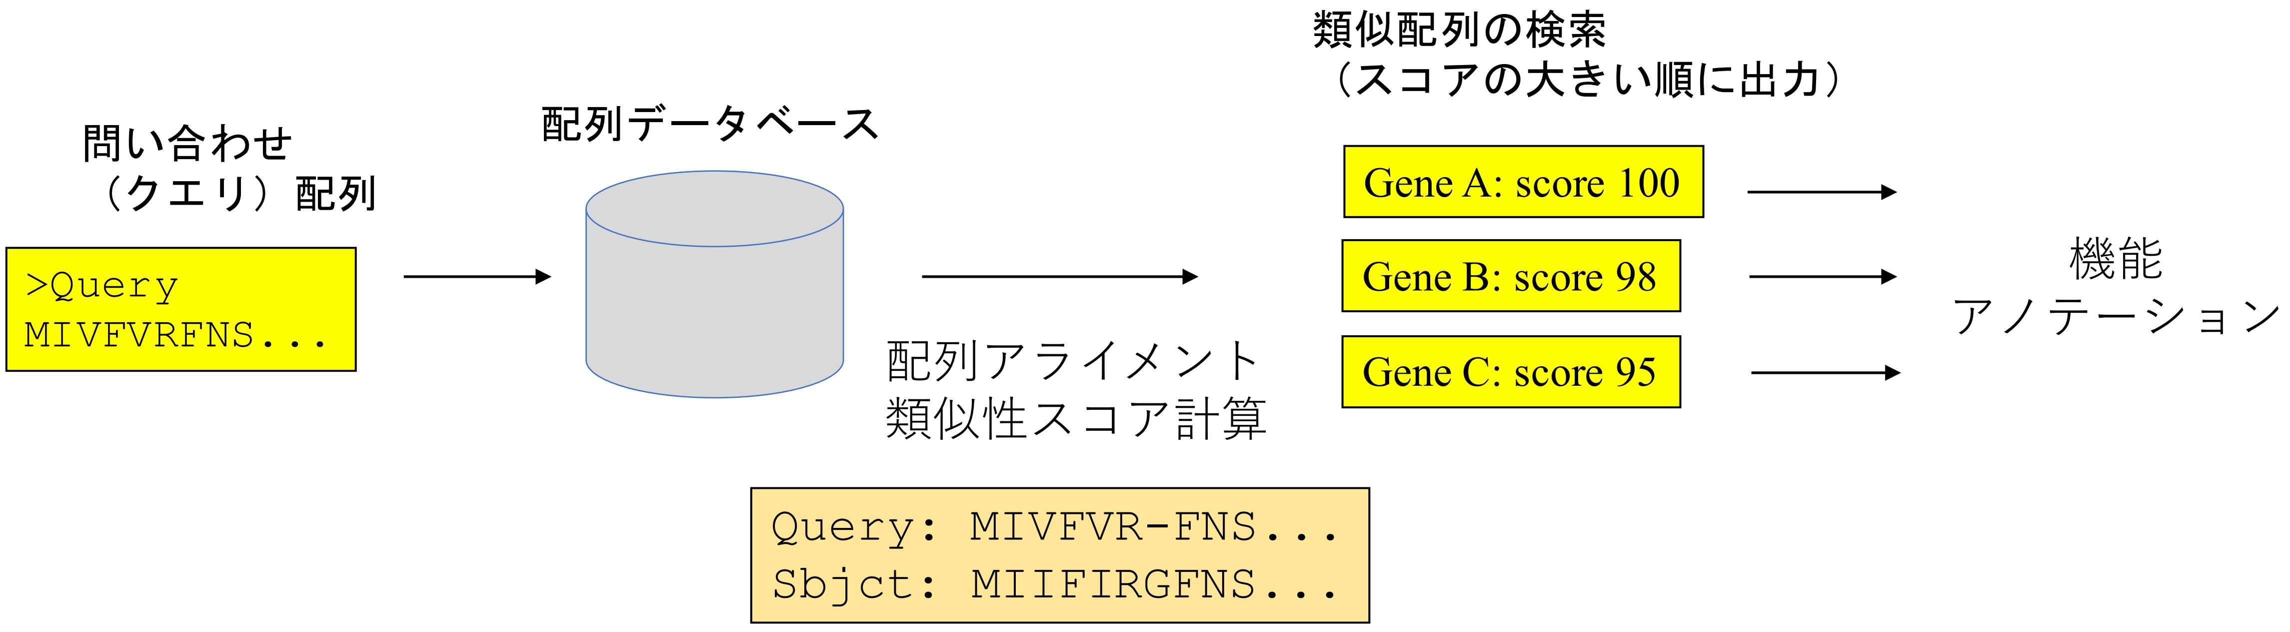

問い合わせ
（クエリ）配列
>Query
MIVFVRFNS...
配列データベース
配列アライメント
類似性スコア計算
Query: MIVFVR-FNS...
Sbjct: MIIFIRGFNS...
類似配列の検索
（スコアの大きい順に出力）
Gene A: score 100
Gene B: score 98
Gene C: score 95
機能
アノテーション

問い合わせ配列の準備

FASTA形式

```
>エントリー名　説明
配列………
>エントリー名　説明
配列………
・・・・・
```

```
>gi|4758884|ref|NP_004553.1| parkin isoform 1 [Homo sapiens]
MIVFVRFNSSHGFPVEVDSDTSIFQLKEVVAKRQGVPADQLRVIFAGKELRNDWTVQNCDLDQQSIVHIV
QRPWRKGQEMNATGGDDPRNAAGGCEREPQSLTRVDLSSSVLPGDSVGLAVILHTDSRKDSPPAGSPAGR
SIYNSFYVYCKGPCQRVQPGKLRVQCSTCRQATLTLTQGPSCWDDVLIPNRMSGECQSPHCPGTSAEFFF
KCGAHPTSDKETPVALHLIATNSRNITCITCTDVRSPVLVFQCNSRHVICLDCFHLYCVTRLNDRQFVHD
PQLGYSLPCVAGCPNSLIKELHHFRILGEEQYNRYQQYGAEECVLQMGGVLCPRPGCGAGLLPEPDQRKV
TCEGGNGLGCGFAFCRECKEAYHEGECSAVFEASGTTTQAYRVDERAAEQARWEAASKETIKKTTKPCPR
CHVPVEKNGGCMHMKCPQPQCRLEWCWNCGCEWNRVCMGDHWFDV
```

BLAST (Basic Local Alignment Search Tool)

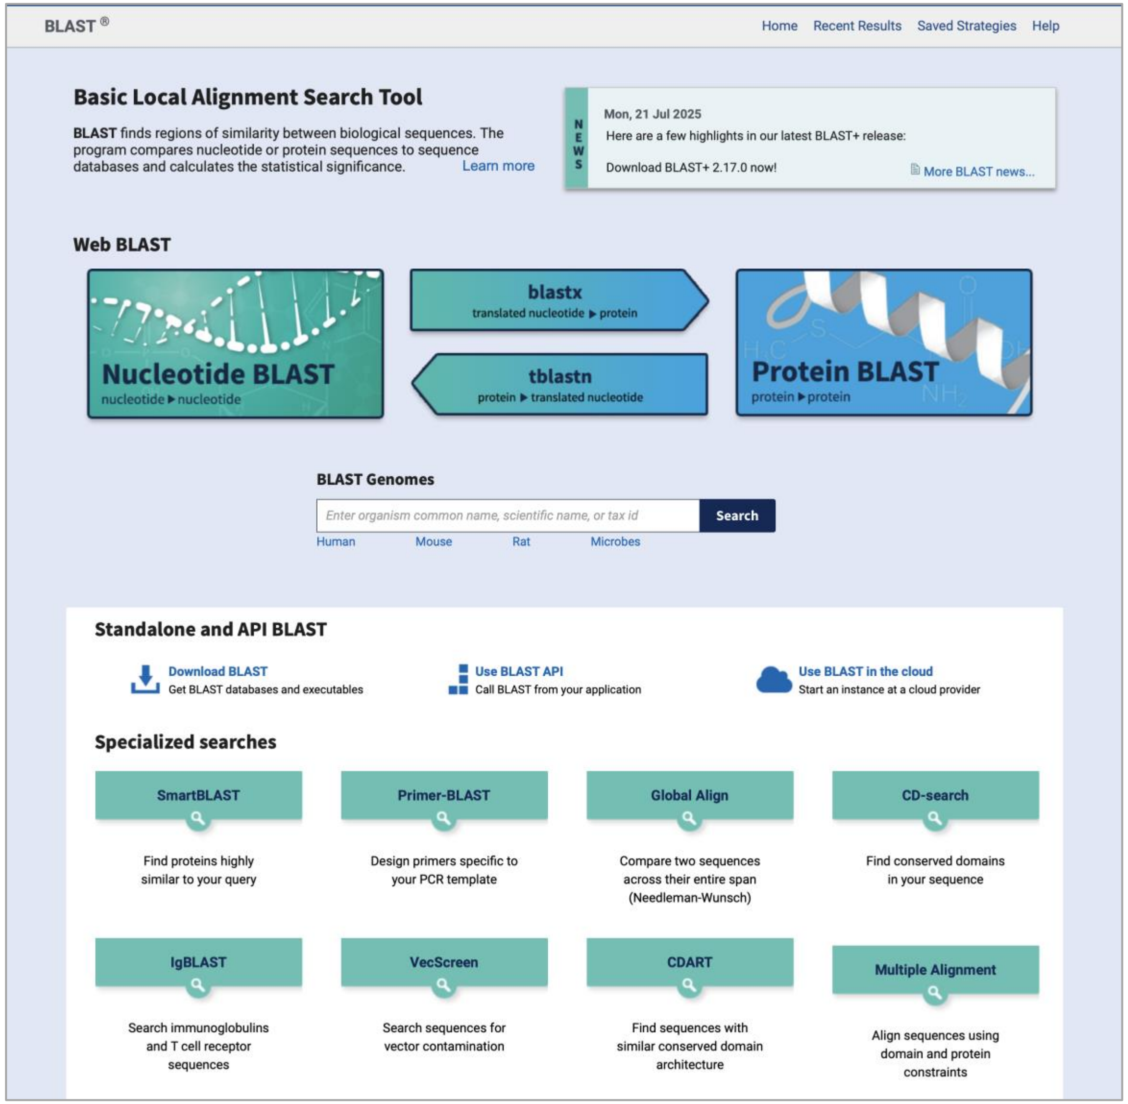

https://blast.ncbi.nlm.nih.gov/Blast.cgi

program	query	database	translation
BLASTP	protein	protein	
BLASTN	nucleotide	nucleotide	
BLASTX	nucleotide	protein	query
TBLASTN	protein	nucleotide	database
TBLASTX	nucleotide	nucleotide	both

- 核酸配列は、相補鎖も同時に検索する
- 翻訳は、各鎖の3つの読み枠、計6通りの読み枠で比較する

BLAST　検索インターフェイス

クエリ配列

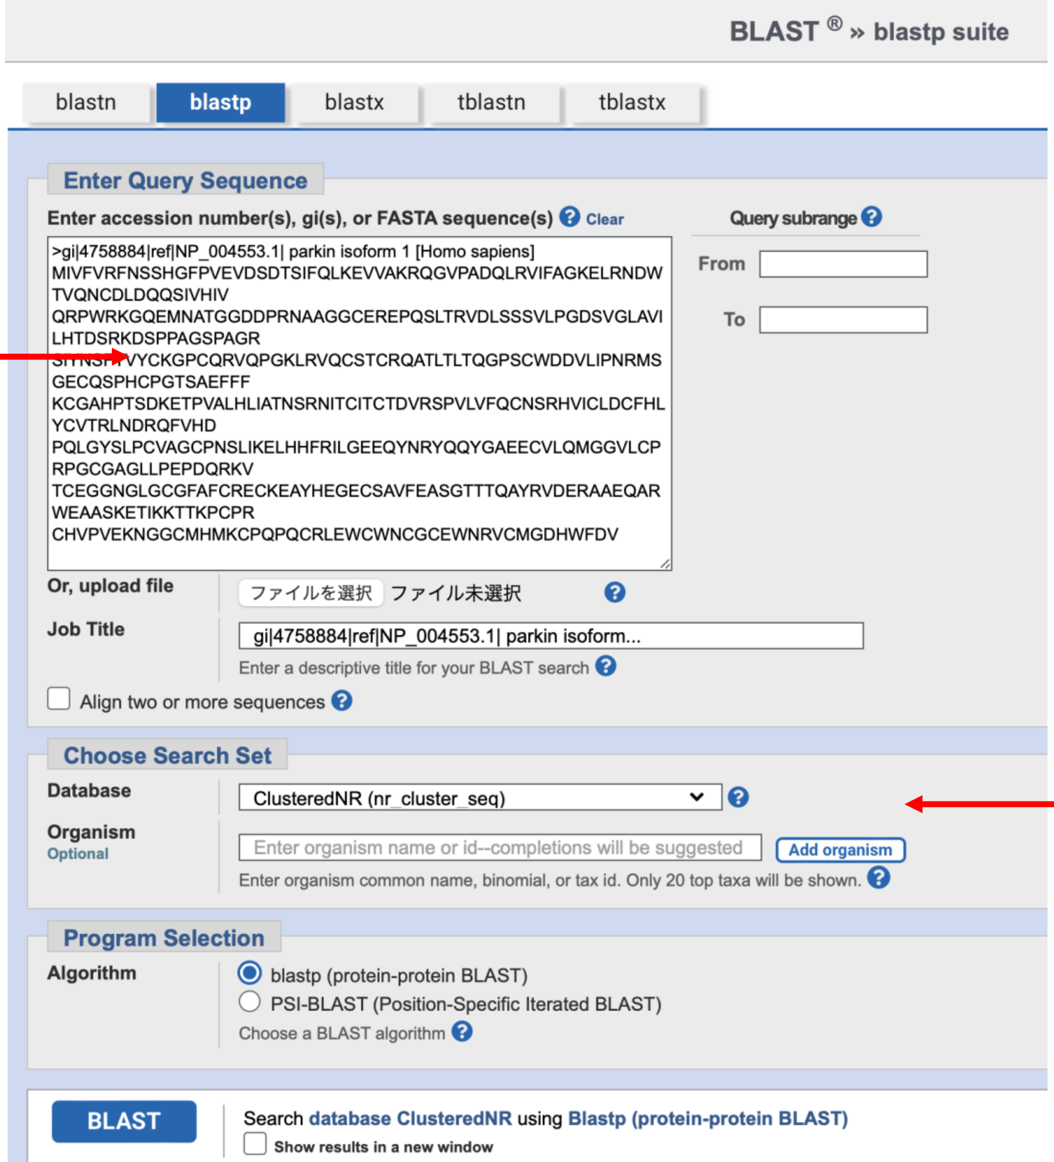

データベース

蛋白質配列データベース

- Non-redundant Protein (nr)
  - 公開されている蛋白質配列(DNA配列を翻訳したものを含む）すべてを統合して、重複（完全に一致した配列）を除いたもの
- ClusteredNR (nr_cluster_seq) **[default]**
  - nr から、さらに90%以上一致した配列をまとめて重複を除いたもの
- RefSeq proteins (refseq_protein)
  - 公的データベースに登録された配列データに対し、NCBIが生物種ごとにゲノムや遺伝子単位で再整理したデータベース（RefSeq）中の蛋白質配列
- UniProtKB/Swiss-Prot（swissprot)
  - EBIで作成されている蛋白質配列データベース。専門家が手作業で注釈づけなどを行っているSwiss-Protと、DNA配列を機械的に翻訳、注釈づけして作成しているTrEMBLとからなる。

BLAST 検索結果

Clusters | Graphic Summary | Alignments | Taxonomy

Clusters producing significant alignments Download Select columns Show 100

select all *100 clusters selected* GenPept Graphics Distance tree of results Multiple alignment MSA Viewer

	Cluster Composition (Click the ⊞ to see the cluster contents)	Cluster Ancestor	Cluster Representative Sequence	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☑	⊞1 member(s), 1 organism(s)	other sequences	fusion protein HA-miRFP670nano-Parkin [synthetic construct]	975	975	100%	0.0	100.00%	627	BET92570.1
☑	⊞4 member(s), 4 organism(s)	primates	E3 ubiquitin-protein ligase parkin isoform X10 [Macaca nemestr...	940	940	100%	0.0	97.19%	530	XP_070952036.1
☑	⊞1 member(s), 1 organism(s)	white-tufted-ear marmoset	E3 ubiquitin-protein ligase parkin isoform X2 [Callithrix jacchus]	929	929	100%	0.0	95.70%	489	XP_078226555.1
☑	⊞82 member(s), 26 organism(s)	primates	E3 ubiquitin-protein ligase parkin isoform 2 [Homo sapiens]	894	894	100%	0.0	93.98%	437	NP_054642.2
☑	⊞8 member(s), 7 organism(s)	prosimians	E3 ubiquitin-protein ligase parkin isoform 1 [Daubentonia mada...	870	870	100%	0.0	89.48%	465	KAL2792878.1
☑	⊞6 member(s), 1 organism(s)	Philippine flying lemur	E3 ubiquitin-protein ligase parkin isoform X4 [Cynocephalus vol...	858	858	100%	0.0	88.55%	480	XP_062952603.1
☑	⊞30 member(s), 18 organism(s)	even-toed ungulates & wh...	E3 ubiquitin-protein ligase parkin isoform X2 [Hippopotamus am...	854	854	100%	0.0	87.31%	495	XP_057594137.1
☑	⊞12 member(s), 6 organism(s)	odd-toed ungulates	E3 ubiquitin-protein ligase parkin isoform X1 [Equus quagga]	853	853	100%	0.0	87.34%	466	XP_046526636.1
☑	⊞2 member(s), 1 organism(s)	Chinese tree shrew	E3 ubiquitin-protein ligase parkin isoform X2 [Tupaia chinensis]	847	847	100%	0.0	87.74%	464	XP_006152316.1
☑	⊞1 member(s), 1 organism(s)	puma	E3 ubiquitin-protein ligase parkin [Puma concolor]	843	843	100%	0.0	86.24%	691	XP_025781231.1
☑	⊞1 member(s), 1 organism(s)	gray mouse lemur	E3 ubiquitin-protein ligase parkin isoform X2 [Microcebus murin...	842	842	100%	0.0	88.60%	464	XP_075858924.1
☑	⊞9 member(s), 4 organism(s)	primates	E3 ubiquitin-protein ligase parkin isoform X2 [Symphalangus sy...	839	839	90%	0.0	95.93%	442	XP_055125023.2
☑	⊞48 member(s), 23 organism(s)	carnivores	E3 ubiquitin-protein ligase parkin isoform X1 [Phoca vitulina]	838	838	100%	0.0	86.39%	469	XP_032263409.1
☑	⊞2 member(s), 1 organism(s)	gray squirrel	E3 ubiquitin-protein ligase parkin isoform X2 [Sciurus carolinen...	838	838	100%	0.0	86.67%	462	XP_047413015.1
☑	⊞1 member(s), 1 organism(s)	American beaver	E3 ubiquitin-protein ligase parkin isoform X1 [Castor canadensis]	836	836	100%	0.0	80.39%	509	XP_073926901.1
☑	⊞5 member(s), 2 organism(s)	elephants	E3 ubiquitin-protein ligase parkin isoform X1 [Elephas maximus...	833	833	100%	0.0	85.16%	465	XP_049762059.1
☑	⊞26 member(s), 14 organism(s)	cat family	E3 ubiquitin-protein ligase parkin isoform X1 [Felis catus]	830	830	100%	0.0	83.26%	481	XP_044914560.1
☑	⊞5 member(s), 2 organism(s)	pigs	E3 ubiquitin-protein ligase parkin [Sus scrofa]	830	830	100%	0.0	86.02%	461	NP_001038068.2
☑	⊞11 member(s), 4 organism(s)	even-toed ungulates & wh...	E3 ubiquitin-protein ligase parkin isoform X2 [Camelus ferus]	828	828	100%	0.0	86.02%	460	XP_032341198.1
☑	⊞2 member(s), 1 organism(s)	prairie deer mouse	E3 ubiquitin-protein ligase parkin isoform X2 [Peromyscus mani...	825	825	100%	0.0	82.24%	489	XP_076408996.1
☑	⊞1 member(s), 1 organism(s)	aardvark	E3 ubiquitin-protein ligase parkin [Orycteropus afer afer]	825	825	100%	0.0	84.23%	467	XP_042637507.1
☑	⊞5 member(s), 1 organism(s)	nine-banded armadillo	E3 ubiquitin-protein ligase parkin isoform X5 [Dasypus novemci...	823	823	100%	0.0	84.30%	464	XP_058145644.1
☑	⊞2 member(s), 2 organism(s)	rabbits & hares	E3 ubiquitin-protein ligase parkin isoform X1 [Ochotona princeps]	823	823	100%	0.0	84.95%	464	XP_058512164.1
☑	⊞58 member(s), 22 organism(s)	rodents	E3 ubiquitin-protein ligase parkin isoform 3 [Mus musculus]	820	820	100%	0.0	83.87%	465	NP_001390399.1
☑	⊞4 member(s), 3 organism(s)	dog, coyote, wolf, fox	E3 ubiquitin-protein ligase parkin isoform X1 [Nyctereutes procy...	818	818	100%	0.0	81.95%	481	XP_055168029.1
☑	⊞1 member(s), 1 organism(s)	Arctic ground squirrel	E3 ubiquitin-protein ligase parkin isoform 1-T1 [Urocitellus parryii]	818	818	100%	0.0	82.85%	482	KAM4816522.1
☑	⊞1 member(s), 1 organism(s)	golden spiny mouse	E3 ubiquitin-protein ligase parkin isoform X3 [Acomys russatus]	817	817	100%	0.0	83.44%	465	XP_051020298.1
☑	⊞3 member(s), 1 organism(s)	Nile rat	E3 ubiquitin-protein ligase parkin isoform X3 [Arvicanthis niloticus]	815	815	99%	0.0	84.63%	461	XP_076782759.1
☑	⊞9 member(s), 3 organism(s)	bats	E3 ubiquitin-protein ligase parkin isoform X1 [Rhinolophus ferru...	814	814	100%	0.0	83.44%	463	XP_032959339.1

E-value
ランダムな配列で、その
スコア以上の類似性を持
つ個数の期待値

BLAST 検索結果

グラフィカル表示

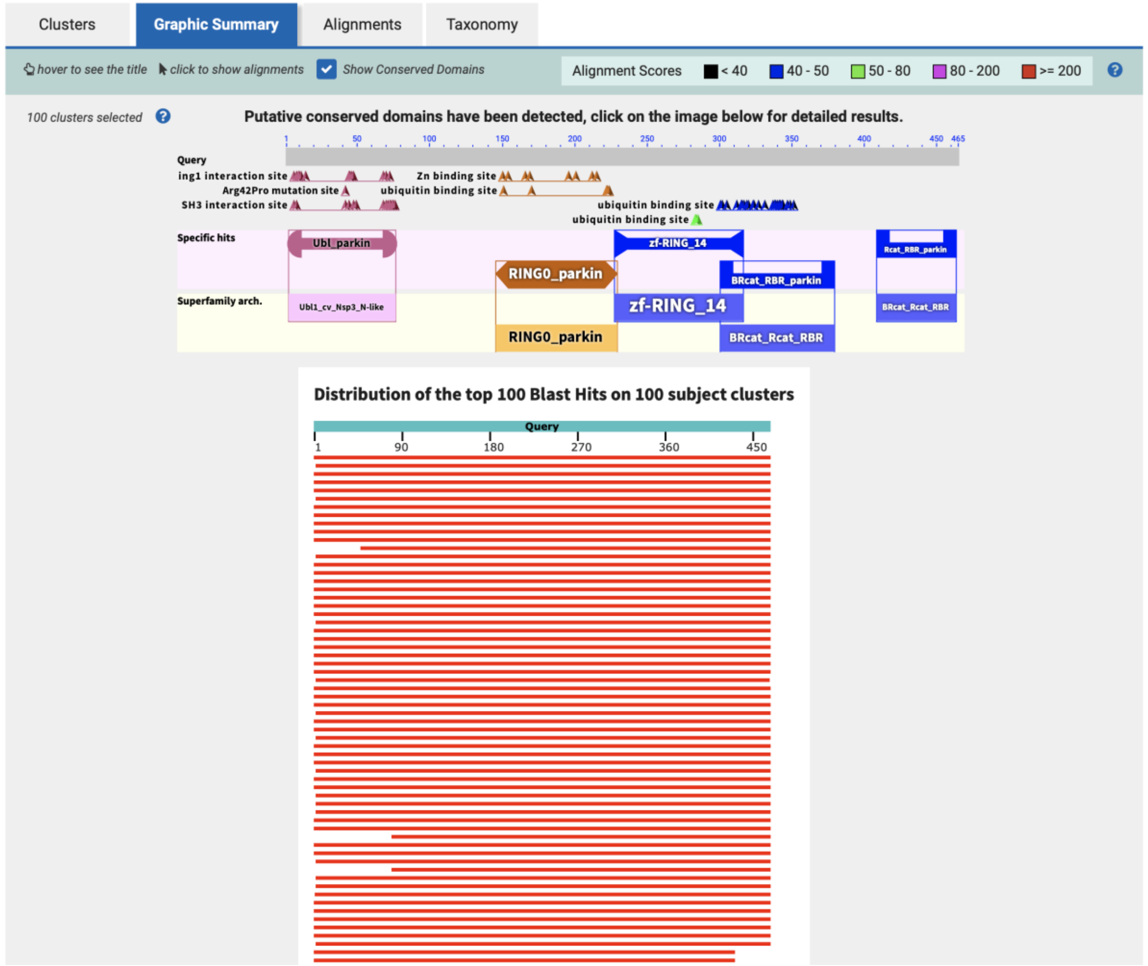

アライメント

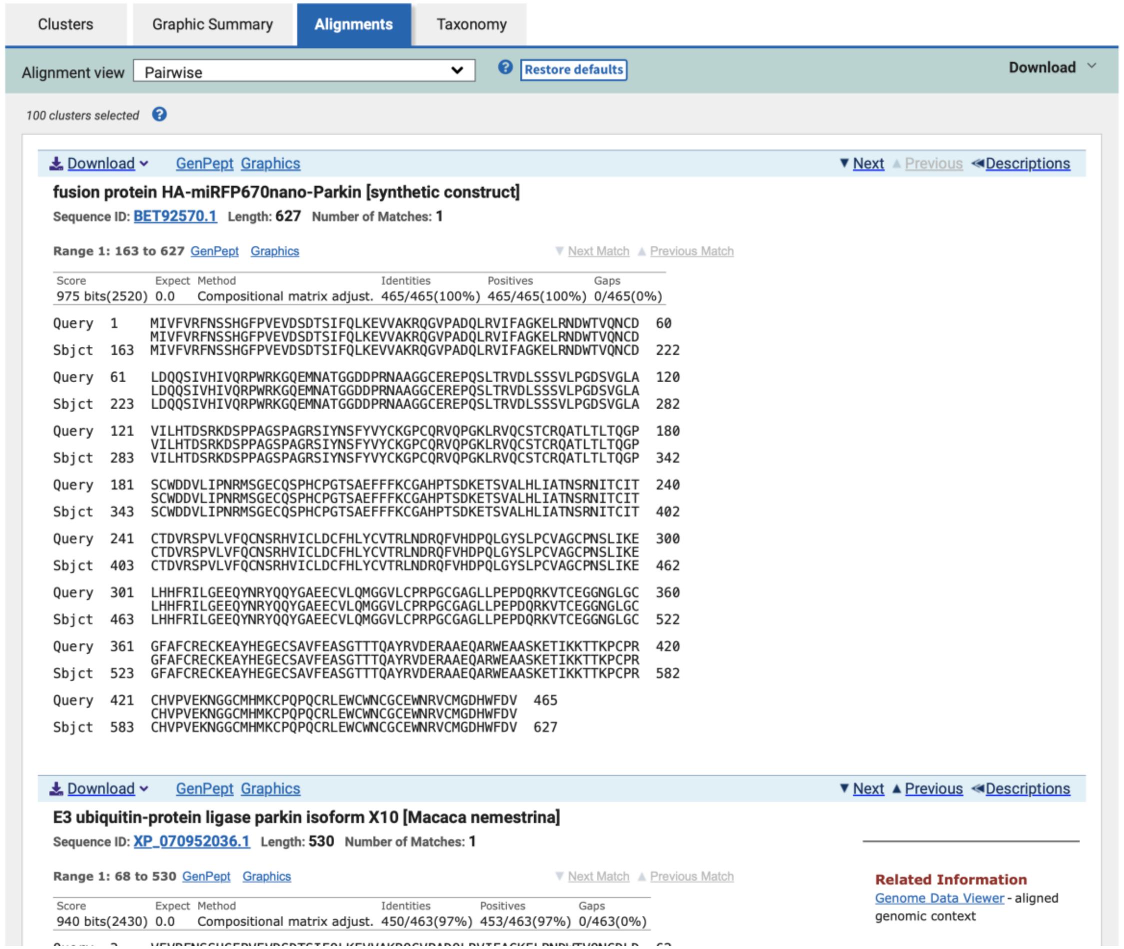

グローバルアライメントとローカルアライメント

- グローバルアライメント
  - 配列全体を比較する

- ローカルアライメント
  - 類似性が最も高くなるような部分配列をとる

- ホモロジー検索では、ローカルアライメントを求める
  - アラインされる領域(HSP) が複数見つかることもある

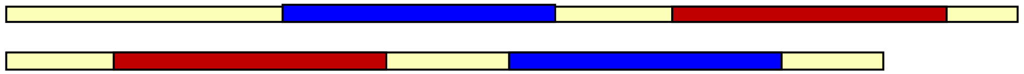

コマンドライン BLAST

プログラム名　–query クエリ配列ファイル –db データベース名

プログラム名： blastp, blastn, tblastn, blastx, tblastx

- SwissProt データベースに対して検索を実行する。
  CPUコア 4つを使って実行する(-num_threads)。
  ```
  % blastp -query query.fa -db swissprot –num_threads 4 > blastout
  ```

- 同じ検索を行い、テーブル形式で出力する(-outfmt 6)。
  ```
  % blastp -query query.fa -db swissprot –num_threads 4 –outfmt 6 > blasttab
  ```

BLASTの出力

```
BLASTP 2.16.0+


Database: SWISS-PROT: SWISS-PROT protein sequence database Release 2025_04
           573,661 sequences; 207,922,125 total letters

Query= gi|4758884|ref|NP_004553.1| parkin isoform 1 [Homo sapiens]

Length=465
                                                                      Score     E
Sequences producing significant alignments:                          (Bits)  Value

O60260 [PRKN_HUMAN] RecName: Full=E3 ubiquitin-protein ligase par...  964      0.0
Q9JK66 [PRKN_RAT] RecName: Full=E3 ubiquitin-protein ligase parki...  830      0.0
Q9WVS6 [PRKN_MOUSE] RecName: Full=E3 ubiquitin-protein ligase par...  812      0.0
Q7KTX7 [PRKN_DROME] RecName: Full=E3 ubiquitin-protein ligase par...  382      7e-128
E0VIU9 [PRKN_PEDHC] RecName: Full=E3 ubiquitin-protein ligase par...  344      3e-113
Q6T486 [RBRA_DICDI] RecName: Full=Probable E3 ubiquitin-protein l...  77.8     5e-14
Q84RR0 [ARI7_ARATH] RecName: Full=Probable E3 ubiquitin-protein l...  77.0     9e-14
Q6PFJ9 [ARI1_DANRE] RecName: Full=E3 ubiquitin-protein ligase ari...  70.5     1e-11
Q9Z1K5 [ARI1_MOUSE] RecName: Full=E3 ubiquitin-protein ligase ARI...  70.5     1e-11
A2VEA3 [ARI1_BOVIN] RecName: Full=E3 ubiquitin-protein ligase ARI...  70.5     1e-11
Q9Y4X5 [ARI1_HUMAN] RecName: Full=E3 ubiquitin-protein ligase ARI...  70.5     1e-11
Q94981 [ARI1_DROME] RecName: Full=E3 ubiquitin-protein ligase ari...  70.1     1e-11
Q6NW85 [ARI1L_DANRE] RecName: Full=E3 ubiquitin-protein ligase ar...  70.1     1e-11
B1H1E4 [ARI1_XENTR] RecName: Full=E3 ubiquitin-protein ligase ari...  69.7     2e-11
Q32NS4 [ARI1_XENLA] RecName: Full=E3 ubiquitin-protein ligase ari...  68.6     4e-11
Q8L829 [ARI5_ARATH] RecName: Full=Probable E3 ubiquitin-protein l...  67.0     1e-10
Q9UBS8 [RNF14_HUMAN] RecName: Full=E3 ubiquitin-protein ligase RN...  65.5     3e-10
Q9Z1K6 [ARI2_MOUSE] RecName: Full=E3 ubiquitin-protein ligase ARI...  65.1     5e-10
P0C8K8 [ARI6_ARATH] RecName: Full=Putative E3 ubiquitin-protein l...  64.7     8e-10
O95376 [ARI2_HUMAN] RecName: Full=E3 ubiquitin-protein ligase ARI...  64.7     8e-10
Q9SKC3 [ARI9_ARATH] RecName: Full=Probable E3 ubiquitin-protein l...  63.5     2e-09
Q9JI90 [RNF14_MOUSE] RecName: Full=E3 ubiquitin-protein ligase RN...  61.6     6e-09
F1RB95 [RNF14_DANRE] RecName: Full=E3 ubiquitin-protein ligase RN...  61.2     9e-09
Q05120 [UBIL_NPVOP] RecName: Full=Ubiquitin-like protein; Flags: ...  55.5     1e-08
```

```
>Q7KTX7 [PRKN_DROME] RecName: Full=E3 ubiquitin-protein ligase
parkin {ECO:0000303|PubMed:12642658}; EC=2.3.2.31 {ECO:0000269|PubMed:17456438,
ECO:0000269|PubMed:20194754, ECO:0000269|PubMed:23770917,
ECO:0000269|PubMed:24901221};
Length=482

 Score = 382 bits (981),  Expect = 7e-128, Method: Compositional matrix adjust.
 Identities = 200/474 (42%), Positives = 280/474 (59%), Gaps = 33/474 (7%)

Query  1    MIVFVRFNSSHGFPVEVDSDTSIFQLKEVVAKRQGVPADQLRVIFAGKELRNDWTVQNCD  60
            + ++V+ N+     V ++    I  +KE+VA + G+  D L++IFAGKEL +  T++ CD
Sbjct  30   LSIYVKTNTGKTLTVNLEPQWDIKNVKELVAPQLGLQPDDLKIIFAGKELSDATTIEQCD  89

Query  61   LDQQSIVHIVQ-RPWRKGQEMNATGGDDPRNAAGGCEREPQSLTRVDLSSSVLPGDSVGL  119
            L QQS++H ++ RP  + Q++ +   ++   +      +P + T +DL
Sbjct  90   LGQQSVLHAIRLRPPVQRQKIQSATLEEEEPSLSDEASKPLNETLLDLQ-----------  138

Query  120  AVILHTDSRKDSPPAGSPAGRSIYNSFYVYCKGPCQRVQPGKLRVQCSTCRQATLTLTQG  179
               L ++ R +         ++    F+V+C   C ++  GKLRV+C+ C+    T+ +
Sbjct  139  ---LESEERLNITDEERVRAKA---HFFVHC-SQCDKLCNGKLRVRCALCKGGAFTVHRD  191

Query  180  PSCWDDVLIPNRMSGECQSPHCPGTS--------AEFFFKCGAHPTS-DKETPVALHLIA  230
            P CWDDVL   R+ G C+S               AEFFFKC  H +  +K+    L+LI
Sbjct  192  PECWDDVLKSRRIPGHCESLEVACVDNAAGDPPFAEFFFKCAEHVSGGEKDFAAPLNLIK  251

Query  231  TNSRNITCITCTDVRSPVLVFQCNSRHVICLDCFHLYCVTRLNDRQFVHDPQLGYSLPCV  290
             N +N+ C+ CTDV   VLVF C S+HV C+DCF  YC +RL +RQF+  P  GY+LPC
Sbjct  252  NNIKNVPCLACTDVSDTVLVFPCASQHVTCIDCFRHYCRSRLGERQFMPHPDFGYTLPCP  311

Query  291  AGCPNSLIKELHHFRILGEEQYNRYQQYGAEECVLQMGGVLCPRPGCGAGLLPEPDQRKV  350
            AGC +S I+E+HHF++L  E+Y+RYQ++  EE VLQ GGVLCP+PGCG GLL EPD RKV
Sbjct  312  AGCEHSFIEEIHHFKLLTREEYDRYQRFATEEYVLQAGGVLCPQPGCGMGLLVEPDCRKV  371

Query  351  TCEGGNGLGCGFAFCRECKEAYHEGECSAVFE-ASGTTTQAYRVDERAAEQARWEAASKE  409
            TC+     GCG+ FCR C + YH GEC      AS T +  Y VD   A +ARW+ AS
Sbjct  372  TCQN----GCGYVFCRNCLQGYHIGECLPEGTGASATNSCEYTVDPNRAAEARWDEASNV  427

Query  410  TIKKTTKPCPRCHVPVEKNGGCMHMKCPQPQCRLEWCWNCGCEWNRVCMGDHWF  463
            TIK +TKPCP+C  P E++GGCMHM C +  C  EWCW C  EW R CMG HWF
Sbjct  428  TIKVSTKPCPKCRTPTERDGGCMHMVCTRAGCGFEWCWVCQTEWTRDCMGAHWF  481
```

テーブル形式出力 (BLAST Tabular format)

1. query	2. subject (database)	3. %identity	4. align-len	5. mismatch	6. gap_open	7. q_start	8. q_end	9. s_start	10. s_end	11. evalue	12. bit-score
gi|4758884|ref|NP_004553.1|	O60260	99.785	465	1	0	1	465	1	465	0.0	964
gi|4758884|ref|NP_004553.1|	Q9JK66	84.946	465	70	0	1	465	1	465	0.0	830
gi|4758884|ref|NP_004553.1|	Q9WVS6	83.441	465	76	1	1	465	1	464	0.0	812
gi|4758884|ref|NP_004553.1|	Q7KTX7	42.194	474	241	8	1	463	30	481	7.05e-128	382
gi|4758884|ref|NP_004553.1|	E0VIU9	38.445	463	249	9	3	463	32	460	2.53e-113	344
gi|4758884|ref|NP_004553.1|	Q6T486	27.823	248	139	10	219	453	117	337	5.20e-14	77.8
gi|4758884|ref|NP_004553.1|	Q84RR0	29.004	231	125	10	231	453	130	329	9.49e-14	77.0
gi|4758884|ref|NP_004553.1|	Q6PFJ9	26.500	200	119	7	257	453	175	349	9.81e-12	70.5
gi|4758884|ref|NP_004553.1|	Q9Z1K5	26.500	200	119	7	257	453	203	377	1.01e-11	70.5
gi|4758884|ref|NP_004553.1|	A2VEA3	26.500	200	119	7	257	453	203	377	1.01e-11	70.5
gi|4758884|ref|NP_004553.1|	Q9Y4X5	26.500	200	119	7	257	453	205	379	1.07e-11	70.5
gi|4758884|ref|NP_004553.1|	Q94981	26.538	260	158	11	209	464	105	335	1.34e-11	70.1
gi|4758884|ref|NP_004553.1|	Q6NW85	26.500	200	119	7	257	453	181	355	1.35e-11	70.1
gi|4758884|ref|NP_004553.1|	B1H1E4	26.500	200	119	7	257	453	177	351	1.75e-11	69.7
gi|4758884|ref|NP_004553.1|	Q32NS4	26.066	211	126	8	257	464	177	360	4.50e-11	68.6
gi|4758884|ref|NP_004553.1|	Q8L829	27.826	230	127	10	232	453	126	324	1.33e-10	67.0
gi|4758884|ref|NP_004553.1|	Q9UBS8	28.319	226	129	8	256	464	239	448	3.33e-10	65.5
gi|4758884|ref|NP_004553.1|	Q9Z1K6	23.137	255	157	9	203	453	110	329	4.63e-10	65.1
gi|4758884|ref|NP_004553.1|	P0C8K8	28.017	232	129	11	230	453	125	326	7.87e-10	64.7
gi|4758884|ref|NP_004553.1|	O95376	24.016	254	156	9	203	453	111	330	7.95e-10	64.7
gi|4758884|ref|NP_004553.1|	Q9SKC3	26.786	224	124	10	235	449	125	317	1.90e-09	63.5
gi|4758884|ref|NP_004553.1|	Q9JI90	26.009	223	136	7	261	464	237	449	6.37e-09	61.6
gi|4758884|ref|NP_004553.1|	F1RB95	26.744	172	104	5	306	462	266	430	8.54e-09	61.2
gi|4758884|ref|NP_004553.1|	Q05120	33.333	72	48	0	1	72	1	72	1.27e-08	55.5

この出力形式は柔軟に変更できる。blastp –help を参照。
例えば、オプションを -outfmt “6 std stitle” とすると、上記の出力に加えて、
13カラム目にデータベース配列のタイトル行を付加することができる。

コマンドライン BLAST
データベースを自前で用意する

makeblastdb –in 配列ファイル –dbtype {prot|nucl} -out データベース名

- 例題：出芽酵母 *Saccharomyces cerevisiae* と分裂酵母 *Schizosaccharomyces pombe* の遺伝子総当たり比較
- 配列ファイル sce.fa （出芽酵母全遺伝子の翻訳配列）にインデックスをつけ、sceというデータベースを作る。

```
% makeblastdb -in sce.fa -dbtype prot -parse_seqids -out sce
```

- 作成したデータベースに対して、spo0.fa（分裂酵母遺伝子の一部）をクエリとして、総当たりの検索を実行する。E-valueの閾値を0.001とし(-evalue)、クエリ当たり上位10個までのヒットを出力する(-max_target_seqs)。

```
% blastp -query spo0.fa -db sce -num_threads 4
      -outfmt 6 -evalue 0.001 -max_target_seqs 10 > spo0_sce.out
```

配列アラインメントに基づく方法

リファレンスゲノムへのマッピング

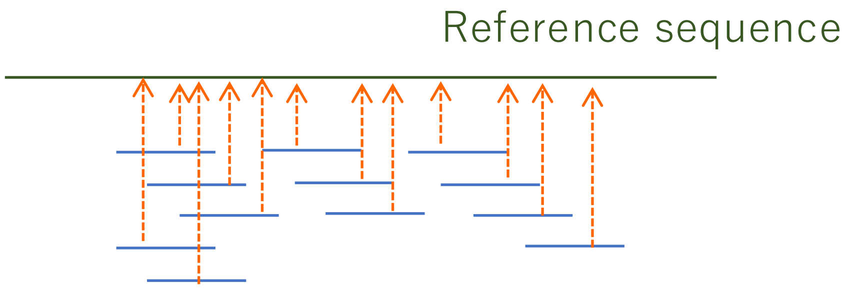

配列アセンブリによる新規配列決定

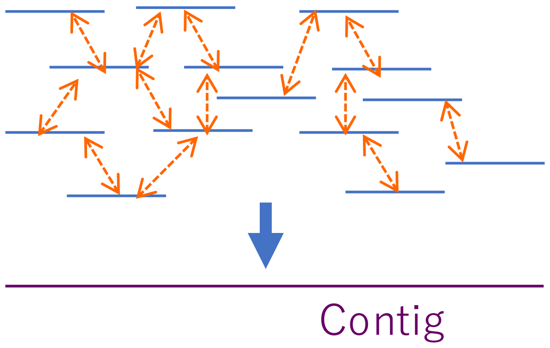

ゲノム配列比較

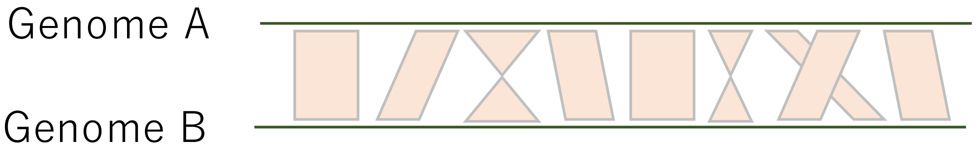

マルチプルアラインメント

```
HBHU      GDLSTPDAVMG--NPKVKAHG---KKVLGAFSDGLAHL---DNLKGTFATLSELHCDKLH
HEGT2     GNLCSESAIMG--NPKVKAHG---RKVLNSFGNAIKHM---DDLKGTFADLSELHCDKLH
HAHU      ------DLSHG--SAQVKGHG---KKVADALTNAVAHV---DDMPNALSALSDLHAHKLR
HACH2     ------DLSHG--SAQIKGHG---KKVVAALIEAANHI---DDIAGTLSKLSDLHAHKLR
MYHU      ---KSEDEMKA--SEDLKKHG---ATVLTALGGILKKK---GHHEAEIKPLAQSHATKHK
GGNKT     --ARLGDVSAGKDNSKLRGHSITLMYALQNFIDALDNV---DRLKCVVEKFAVNHINRQ-
S10238    SFLKDFDEVPQ-NNPSLQAHA---EKVFGLVRDSAAQLRATGVVVLADASLGSVHVQKG-
```

モチーフ抽出
モチーフ検索

```
A 0050000000
R 0000000000
N 0000000000
D 0000000000
C 0000050050
:     :
T 0001000000
W 0200500000
Y 0100000000
```

系統樹作成